

# Suchalgorithmen im Machine Learning

Optimierungsverfahren für Ingenieure

---

Jan Hoegen

2. Dezember 2025

Hochschule Karlsruhe

University of Applied Sciences

# Inhaltsverzeichnis

1. Problemstellung
2. Lösung mit klassischen Algorithmen
3. Lösung mit Bayesian Search
4. Vergleich und Fazit

## Problemstellung

---

# Ein einfaches Beispiel

Blackbox  $b$ :

- Eingabe: Bild
- Ausgabe: Klasse (Hund, Katze, Auto, ...)
- Ergebnis jedoch nicht immer korrekt

$$b(\text{Bild}) \rightarrow \text{Klasse}$$

Training der Blackbox:

- Parameter von  $b$  werden verbessert, wenn das Ergebnis falsch ist
- Größe: 500 000 Parameter
- Datensatz: 60 000 Bilder

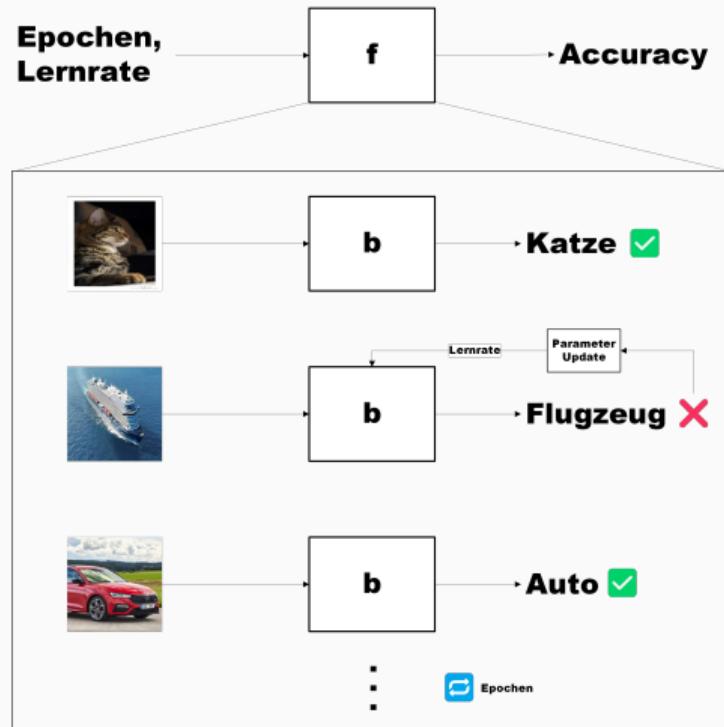
# Genauigkeit der Blackbox als Optimierungsziel

Zielfunktion  $f \rightarrow$  Accuracy:

Prozess: Trainiert die Blackbox  $b$   
über alle Bilder

Ausgabe: Genauigkeit von  $b$  nach  
dem Training

# Genauigkeit der Blackbox als Optimierungsziel



$f(\text{Epochen}, \text{Lernrate}) \rightarrow \text{Accuracy}:$

Prozess: Trainiert die Blackbox  $b$  über alle Bilder

Ausgabe: Genauigkeit von  $b$  nach dem Training

Eingaben:

- Epochen: Wie häufig wird der gesamte Datensatz durchlaufen
- Lernrate: Stärke der Parameteranpassung

Abbildung 1: Darstellung der Zielfunktion.

# Zielsetzung der Optimierung

Ziel:

- Werte für Epochen und Lernrate finden, um die beste Accuracy zu erhalten

Problem:

- Jede Berechnung von  $f$  dauert sehr lange (Minuten bis Stunden)

Lösung:

- Mit lediglich 25 Berechnungen von  $f$  das beste Ergebnis finden
- Effiziente Suchstrategien nutzen

## Lösung mit klassischen Algorithmen

---

# Grid Search

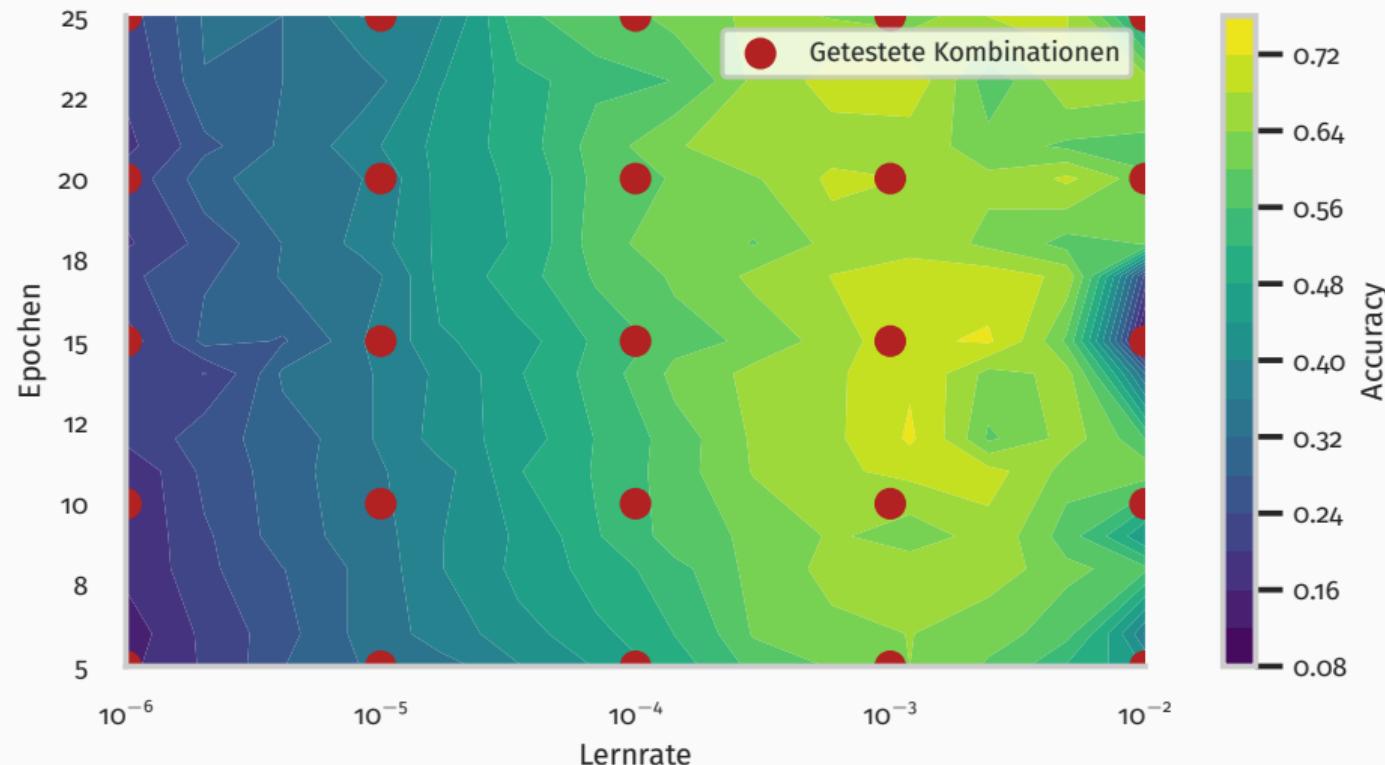


Abbildung 2: Accuracies mit Grid Search Algorithmus

# Random Search

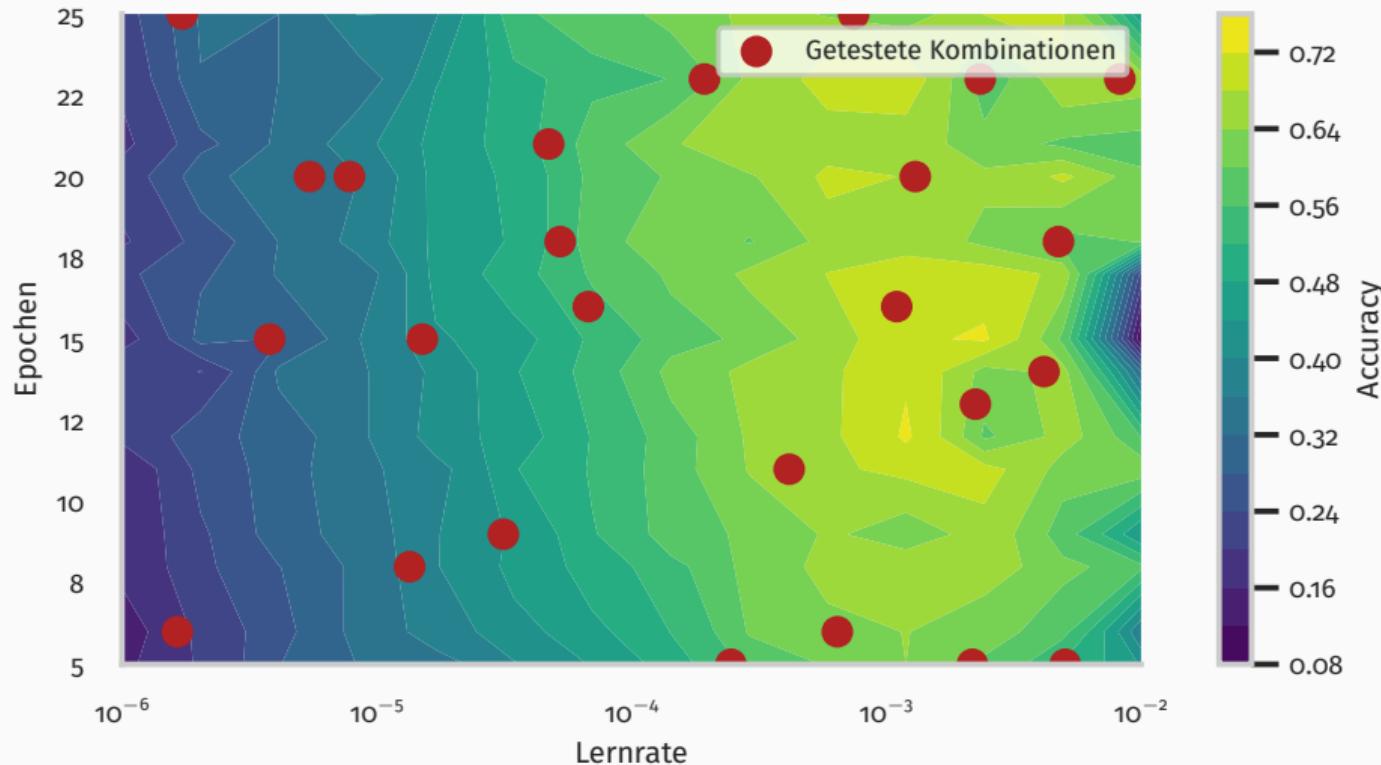


Abbildung 3: Accuracies mit Random Search Algorithmus

## Lösung mit Bayesian Search

---

# Die Idee von Bayesian Search

**Modell:**  $m(\text{Epochen}, \text{Lernrate}) \rightarrow \text{Accuracy}$

- Näherung der Zielfunktion  $f(\text{Epochen}, \text{Lernrate})$
- schnell auswertbar
- Wird nach jeder neuen Auswertung von  $f$  weiter verbessert

**Exploitation:** Vorhandenes Wissen nutzen

- Wähle Punkte, an denen  $m$  eine hohe Accuracy vorhersagt
- $f$  an dieser Stelle berechnen → vermutlich neuer Bestwert

**Exploration:** Unbekannte Bereiche ausprobieren

- Wähle Punkte, an denen  $m$  und  $f$  stark voneinander abweichen könnten
- Verbessert das Modell und entdeckt neue gute Bereiche

# Animation zu Bayesian Search in 1D

**Abbildung 4:** Bayes'sche Scoreoptimierung für einen Random-Forest-Klassifizierer

**Quelle:** [1]

**Legende:**

x-Achse: Parameter.

Schwarz: Zielfunktion.

Lila: Modell mit Unsicherheitsbereich.

*Expected Improvement:* Erwarteter Zugewinn gegenüber dem aktuellen Bestwert.

*Upper Confidence Bound:* Finde vielversprechende, aber unerkundete Bereiche.

*Probability of Improvement:* Wahrscheinlichkeit, einen besseren Punkt zu finden.

# Ergbnisse mit Bayesian Search

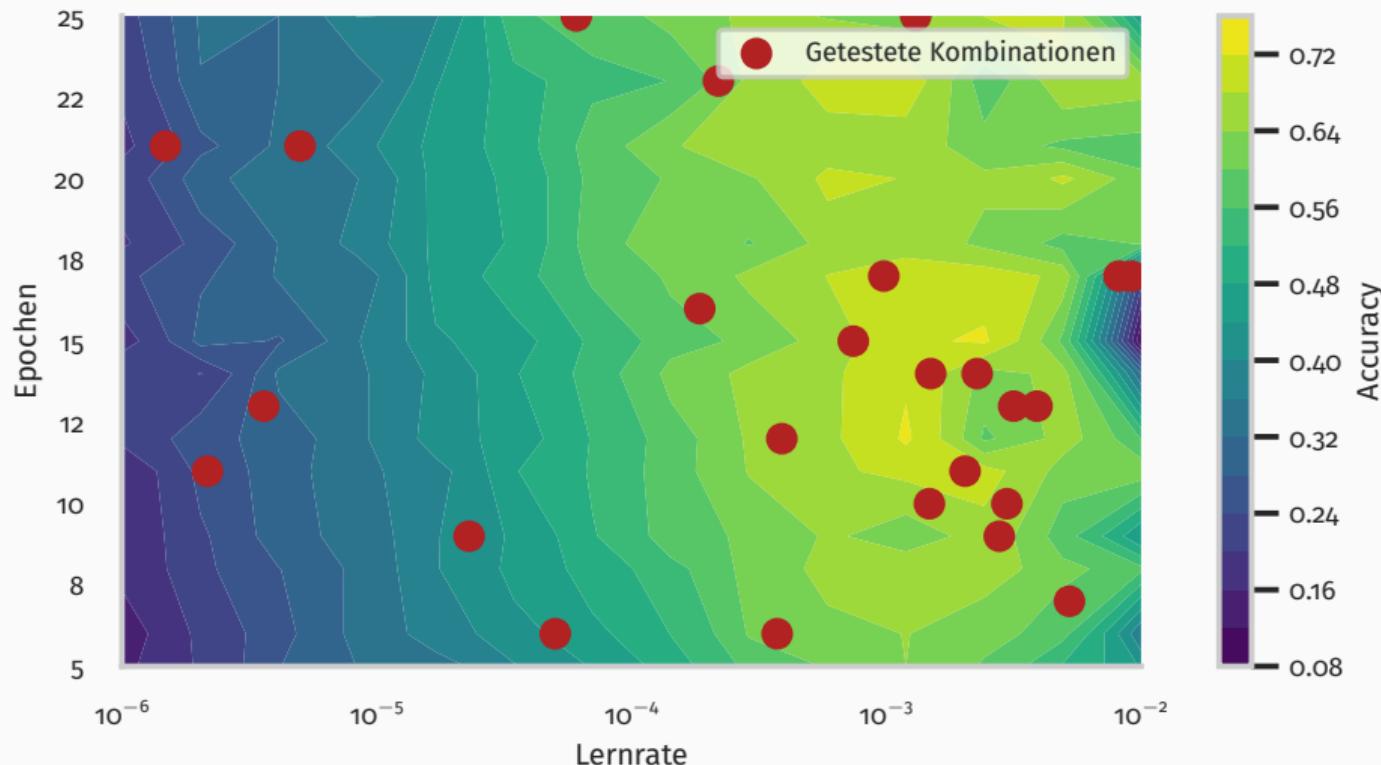


Abbildung 5: Accuracies mit Bayesian Search Algorithmus

## Vergleich und Fazit

---

# Vergleich der Suchalgorithmen

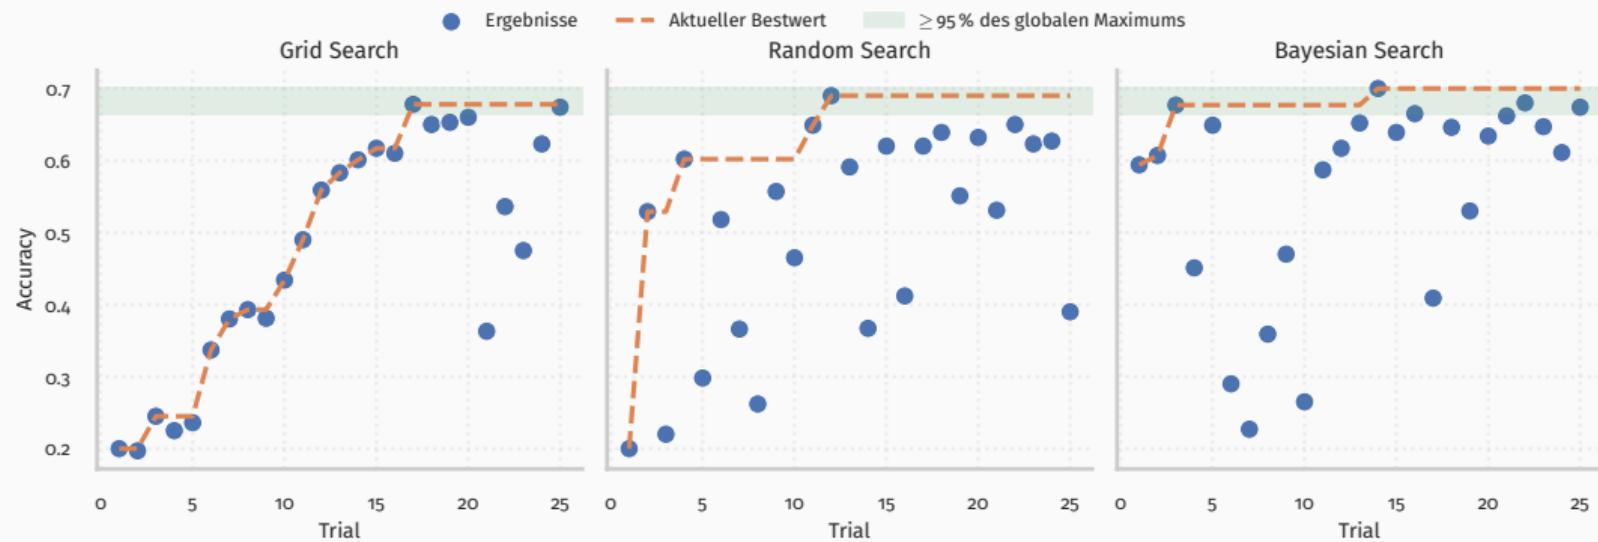


Abbildung 6: Geschwindigkeit und Genauigkeit der Suchalgorithmen

Fragen?

# Literatur

- [1] AnotherSamWilson, „**Bayesian optimization of a function with a Gaussian process**“, besucht am 27. Okt. 2025. Adresse:  
<https://github.com/AnotherSamWilson/ParBayesianOptimization>
- [2] D. Davies, „**What Is Bayesian Hyperparameter Optimization?**“, besucht am 2. Dez. 2025. Adresse:  
[https://wandb.ai/wandb\\_fc/articles/reports/What-Is-Bayesian-Hyperparameter-Optimization-With-Tutorial---Vmlldzo1NDQyNzcv](https://wandb.ai/wandb_fc/articles/reports/What-Is-Bayesian-Hyperparameter-Optimization-With-Tutorial---Vmlldzo1NDQyNzcv)

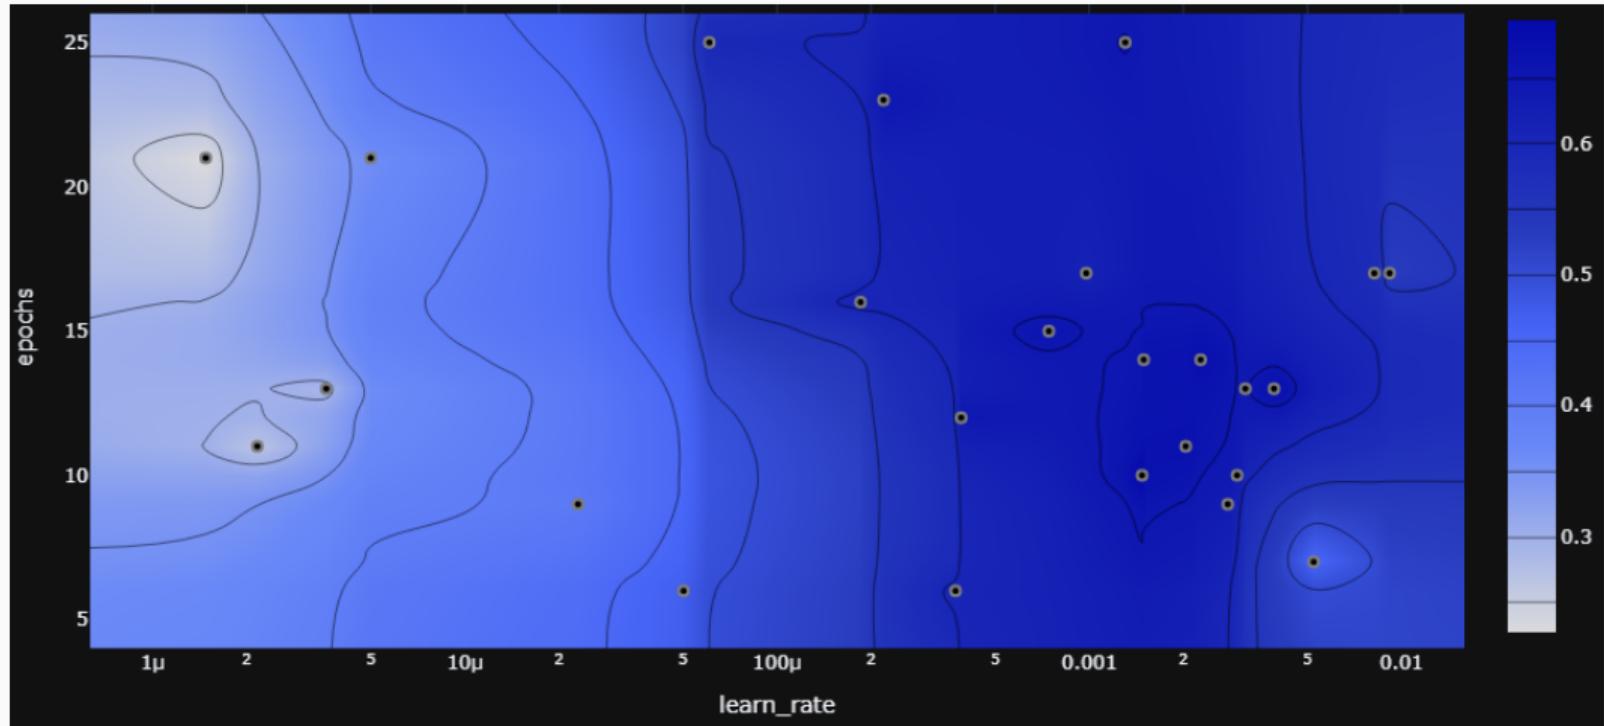


Abbildung 7: Contour Plot aus Bayesian Search Algorithmus

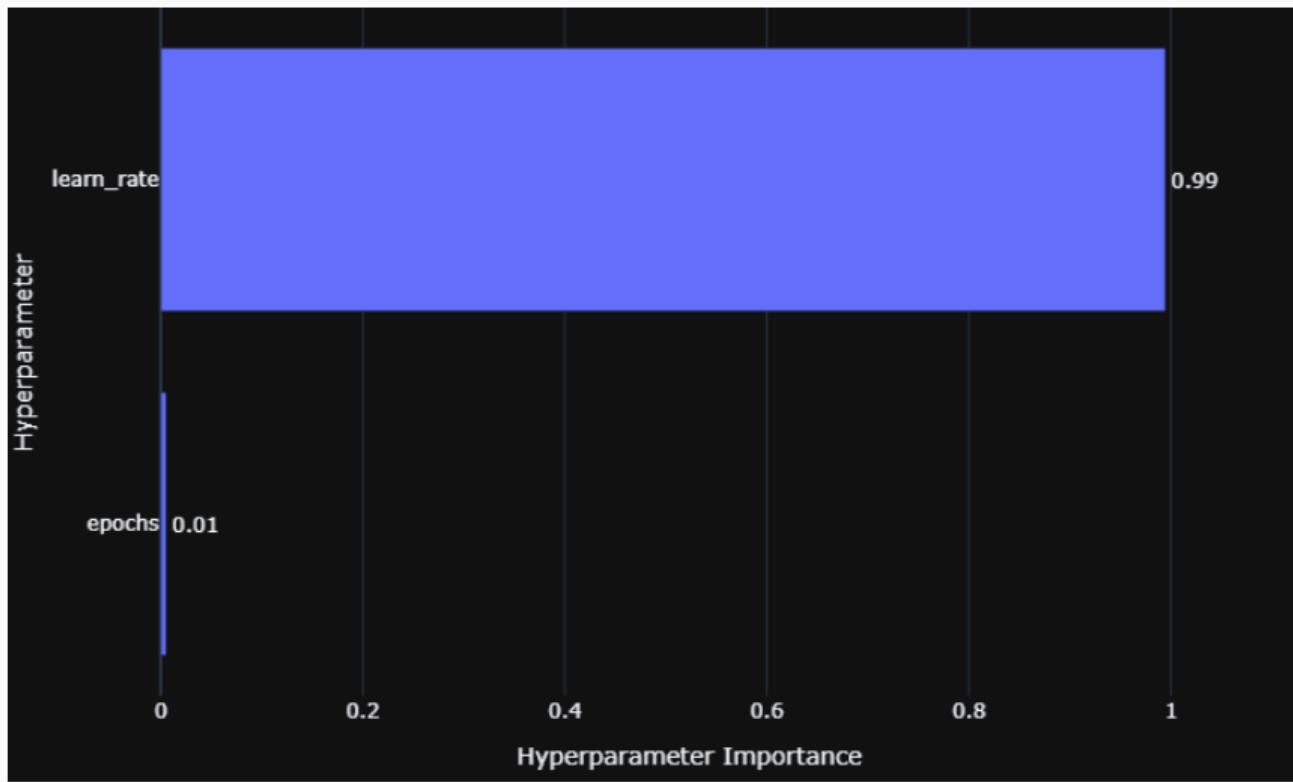


Abbildung 8: Relative Wichtigkeit der Eingangsparameter